

Modul: Data & Process Integration
Studiengang: Strategisches Informationsmanagement
Semester: SoSe2026
Dozent: Prof. Dr. Markus Grüne

Fallstudie Tierarztpraxis Canini - Zwischenbericht -



Name: Jenisa Sivagnanalingham (1121105)
Team: zorro (Szenario B)

Abgabedatum: 21. Juni 2026

1. Projektaufgabe

Gegenstand dieser Fallstudie ist der Zusammenschluss von Patientendaten aus vier Tierarztpraxen (Juckstadt, Waldrand, Schmidt und Bergblick) in einer zentralen Datenbank. Die Kernherausforderung liegt dabei in der Harmonisierung der heterogenen Rohdaten, da die Datensätze in unterschiedlichen Formaten (CSV, JSON, XML) und Strukturen vorliegen und qualitative Mängel enthalten können. Ziel ist es, diese Daten zu bereinigen und in ein einheitliches Zielschema (Golden Records) zu überführen.

Im Rahmen des spezifischen Szenarios B wird für die Dublettenerkennung ein KI-gestützter Ansatz verfolgt. Anstelle von manuell definierten SQL-Abfragen erkennt eine Kombination aus semantischer Vektorsuche und einem Sprachmodell (LLM) redundante Datensätze.

Der vorliegende Zwischenbericht dokumentiert die Ergebnisse und Fortschritte des Teams Zorro aus den Projektwochen 7 bis 9.

2. Ausgangslage & Daten-Profiling (W7)

In Woche 7 sollten die Rohdaten untersucht werden, um die vorliegende Datenqualität zu bewerten und ein Mapping für das spätere Zielschema vorzubereiten. Hierbei wurden signifikante Probleme identifiziert, die eine Tabellenzusammenführung erschweren, wie z. B.:

- **Fehlende referentielle Integrität:** In den Praxen Juckstadt und Schmidt fehlen eindeutige Kunden-IDs (Foreign Keys) in den Behandlungsdaten. Die Verknüpfung erfolgt unsauber über Textfelder (Nachname + Initiale).
- **Schema-Unterschiede:** Bergblick kombiniert Vor- und Nachnamen, während andere Praxen diese trennen. Waldrand verwendet rein englische Attribute (z. B. `customer_id`, `species`).
- **Semantische Fehler & Tippfehler:** Hohe Anzahl an Buchstabendrehern (z. B. „Pteers“, „Wlof“) sowie Vornamen, die nur als Initialen vorliegen.
- **Format-Inkonsistenzen:** Vermischung von US-Datumsformaten (MM/DD/YYYY), deutschen Formaten und ISO 8601, sowie inkonsistente Währungsformate (Komma vs. Punkt).

Diese Defizite sind im „Data Dictionary“ dokumentiert. Dieses dient als Grundlage für die spätere Datenbereinigung und stellt sicher, dass alle Attribute trotzdem korrekt in das einheitliche Zielschema überführt werden können.

3. Architektur und Staging (W8)

In Woche 8 wurden die Daten in eine lokale DuckDB-Datenbank geladen (`verbund.duckdb`). Alle Sprach- und Embedding-Modelle laufen lokal über das Ollama-Framework.

Die Quelldateien erforderten spezifische Import-Methoden:

- **`CSV`-Dateien (Juckstadt, Waldrand, Schmidt):** Diese Tabellen wurden mithilfe der Python-Bibliothek `pandas` eingelesen. Dabei musste auf unterschiedliche Trennzeichen geachtet werden (z. B. Semikolons bei Juckstadt, Kommas bei Waldrand etc.).
- **`JSON`-Dateien (Schmidt Behandlungen):** Die `JSON`-Daten wurden beim Einlesen abgeflacht (Flattening), um aus den Objekten eine zweidimensionale Tabelle zu erzeugen.
- **`XML`-Dateien (Bergblick):** Das Python-Modul `xml.etree.ElementTree` parst die `XML`-Datei hierarchisch und überführt sie in ein tabellarisches Format.

Zur lückenlosen Rückverfolgbarkeit erhielt jeder Datensatz über die Funktion `row_number()` eine eindeutige `quell_zeile`.

Um Tippfehler und abweichende Strukturen zu umgehen, folgte die semantische Vektorisierung (`02_embeddings.py`). Dafür wurden die Kundendaten zu Textketten serialisiert. Das Modell `nomic-embed-text` übersetzte diese anschließend in 768-dimensionale Vektoren (Zahlenreihen).

Das Modell erfasst die inhaltliche Bedeutung. Ähnliche Patienten werden nah beieinander in einem mathematischen Raum angeordnet, sodass Dubletten trotz starker Schreibfehler zuverlässig identifiziert werden können.

4. Matching und Transformation (W9)

Ein direkter Vergleich aller 916 Patienten würde zu über 419.000 möglichen Paaren führen. Daher wird der Suchraum zunächst reduziert:

- **Vorfilterung:** Das Skript `03_vector_search.py` nutzt einen sogenannten `HNSW-Index`, um für jeden Patienten mathematisch nur die 10 ähnlichsten Nachbarn zu ermitteln. Dadurch werden über 98,5 % der irrelevanten Paare aussortiert, sodass noch 5.927 Kandidaten übrig bleiben.
- **Der LLM-Judge:** Die Top 25 werden dann an das lokale Sprachmodell (`qwen2.5:7b`) übergeben (`04_llm_judge.py`). Mithilfe der Python-Bibliothek `Pydantic` gibt das Modell seine Entscheidung in einem definierten `JSON`-Format aus. Dieses enthält ein klares Urteil (Dublette: Ja/Nein), einen prozentualen Konfidenzwert und eine kurze Begründung.
- **Datenbereinigung:** Parallel zur KI-Bewertung sorgt das Skript `05_transform.py` für die formelle Bereinigung der restlichen Daten. Basierend auf dem Data Dictionary aus Woche 7 werden dabei Datumsangaben in das einheitliche `ISO`-Format (`YYYY-MM-DD`) konvertiert und Geldbeträge für spätere Berechnungen in echte Zahlen umgewandelt (z. B. Komma zu Punkt).

5. Fazit

Der Testlauf in Woche 9 bestätigte die Vorteile des KI-gestützten Ansatzes. Das Modell erkannte nicht nur einfache Tippfehler zuverlässig, sondern demonstrierte auch logisches Kontextverständnis. So wurden beispielsweise zwei Einträge für ein Tier namens „Minka“ beim selben Halter aufgrund abweichender Geburtsdaten korrekt als zwei verschiedene Tiere klassifiziert.

Eine signifikante Herausforderung stellte jedoch die Performance dar. Die lokale Ausführung des LLM-Judges beanspruchte teilweise drei bis fünf Minuten pro Dubletten-Prüfung und verzeichnete bei fortlaufenden Anfragen (ab dem sechsten Paar) erhebliche Verzögerungen.

In Woche 11 werden diese identifizierten Dubletten aufgelöst, um die bereinigten „Golden Records“ in die finale Zieldatenbank zu laden.

Anhang: Ergebnisse des LLM-Judges (qwen2.5:7b)

Die nachfolgende Tabelle zeigt einen Auszug der Bewertung der Top-Kandidatenpaare durch das lokale Sprachmodell qwen2.5:7b im Rahmen der Dubletten-Prüfung.

Paar-ID	Urteil	Sicherheit	Signal	Begründung (LLM-Judge)
4392	● DUBLETTE	95.0%	ADDRESS	Vollständige Übereinstimmung in allen Feldern (Name, Adresse, Kontakt). Unterschiede liegen nur im Erstellungsdatum. (Systemdublette)
5890	● KEINE DUBLETTE	60.0%	ADDRESS	Starke Übereinstimmung (Halter Minka, Adresse, Tierart Katze). Jedoch erhebliche Abweichung im Geburtsdatum (2021 vs. 2024). Deutet auf zwei verschiedene Tiere desselben Halters hin.
4525	● KEINE DUBLETTE	60.0%	NAME	Übereinstimmung bei Tierart (Hund) und Geburtsdatum. Starke Abweichungen bei Telefonnummer, E-Mail und Straße.
5208	● KEINE DUBLETTE	60.0%	NAME	Erhebliche Unterschiede in Adresse (Schlossstr. vs. Am Markt), Telefon, E-Mail und Geburtsdatum (2022 vs. 2021). Eindeutig zwei verschiedene Entitäten.
3245	● KEINE DUBLETTE	70.0%	ADDRESS	Gleicher Name (Paul Frank). Abweichende PLZ und Ortsteile (Buederbach vs. Niedergirmes) sowie unterschiedliche Kontakt- und Erfassungsdaten (2019 vs. 2023).
4382	● DUBLETTE	95.0%	NAME	Identische Stammdaten. Modell erkennt Casing-Inkonsistenz ('sonnenwall' vs. 'Sonnenwall') korrekt als reinen Erfassungs-/Tippfehler.