

Modul: Data & Process Integration
Studiengang: Strategisches Informationsmanagement
Semester: SoSe2026
Dozent: Prof. Dr. Markus Grüne

Fallstudie Tierarztpraxis Canini - Ergebnisbericht & Reflexion -



Name: Jenisa Sivagnanalingham (1121105)
Team: zorro (Szenario B)

Abgabedatum: 5. Juli 2026

1. Stand der Ziel-Datenbank

Die entwickelte ETL- und Entity-Resolution-Pipeline wurde erfolgreich und vollständig implementiert. Alle 916 Kundendatensätze und 600 Behandlungsdatensätze aus den vier heterogenen Praxissystemen (Juckstadt, Waldrand, Schmidt, Bergblick) wurden über die Staging- und Transformationsschicht in die finale Ziel-Datenbank (verbund.duckdb) überführt.

Im Rahmen des KI-gestützten Dubletten-Matchings (mittels lokalem LLM qwen2.5:7b-instruct und nomic-embed-text Vektorsuche) wurden redundante Patientenprofile identifiziert und mittels Cluster-Bildung (Transitive Hülle) bereinigt.

Aktueller Datenstand im Zielschema:

- **Golden Records (verbund_kunde):** Aus den ursprünglichen 916 Rohdatensätzen wurden **893** eindeutige, konsolidierte Verbund-Kunden erzeugt.
- **Behandlungen (verbund_behandlung):** Alle **600** Behandlungsdatensätze konnten durch fehlertolerante LEFT JOIN-Logiken verlustfrei auf die neuen Golden Records referenziert werden.
- Das Zielschema ist vollständig relational und erfüllt alle Anforderungen an referentielle Integrität.

2. Vergleich mit Team "Brainicles"

Das Team "Brainicles" bearbeitete dieselbe Datengrundlage, wählte für die Dublettenerkennung (Entity Resolution) jedoch einen anderen methodischen Ansatz. Dieser Vergleich liefert wertvolle Erkenntnisse über die Trade-offs zwischen klassischem Data Engineering und generativer KI.

Methodischer Unterschied:

- **Team Brainicles:** Nutzte einen deterministischen, regelbasierten Ansatz. Zur Reduktion des Suchraums (Blocking) wurden harte Kriterien wie gleiche PLZ und der gleiche Anfangsbuchstabe des Nachnamens verwendet (1.789 Kandidatenpaare). Das Matching erfolgte über String-Distanz-Metriken (Levenshtein-Distanz für Name und Adresse).
- **Team Zorro:** Nutzte einen semantischen KI-Ansatz. Das Blocking erfolgte über Vektor-Embeddings und Kosinus-Distanz (KNN-Suche). Die finale Entscheidung traf ein LLM, das strukturiert via Pydantic antwortete. Aufgrund der begrenzten Hardware-Leistung wurde der Testlauf künstlich auf die Top 30 Paare limitiert (Dauer: ca. 2,5 Minuten pro Paar -> bei 2600 Paaren hätte es 4,5 Tage gebraucht)

Gegenüberstellung der Metriken:

Metrik	Team Zorro (KI-basiert / Limitiert)	Team Brainicles (Regelbasiert / Vollständig)
Golden Records	893	799
Precision	100,00 % (0 False Positives)	99,21 % (1 False Positive)
Recall	16,67 %	91,91 %
F1-Score	28,57 %	95,42 %

Analyse des Vergleichs:

Die Ergebnisse von Team Brainicles zeigen einen hervorragenden F1-Score von über 95 %. Ihr klassischer Ansatz ist extrem performant und konnte über den gesamten Datensatz angewendet werden, was zur Identifikation von deutlich mehr Dubletten führte (Reduktion auf 799 Golden Records). Der KI-Ansatz fällt beim Recall (ca. 17 %) stark ab, was jedoch **der künstlichen Hardware-Limitierung** auf 30 geprüfte Paare geschuldet ist. Der Vorteil des LLM-Ansatzes zeigt sich im ersten Blick in der **Precision von 100 %**. Jedoch muss auch hier beachtet werden, dass die Precision bei der Überprüfung aller möglichen Paare sehr wahrscheinlich schlechter abgeschnitten hätte. Hinzu kommt, dass die LLM von den 30 Paaren 7 ausgeschlossen hatte, da die LLM den Konfidenzwert nicht im gewünschten Format geliefert hatte (95 statt 0,95). Diese wurden nicht bewertet, sondern nach mehreren Versuchen schlichtweg übersprungen. Warum dies trotz Pydantic und dem Prompt Script passiert ist, ist nicht ganz klar. Eventuell müssen diese nochmal strikter definiert werden. Fakt ist jedoch, dass hier möglicherweise Dubletten übersehen wurden, was die Precision ebenfalls verschlechtern würden.

3. Kurze Reflexion & Optimierungspotenzial

Das Projekt war von einem iterativen Optimierungsprozess geprägt, da der erste Prototyp an der Realität der fehlerhaften Quelldaten scheiterte. Zu Beginn führten unsaubere JSON-Antworten des LLMs regelmäßig zu Skript-Abstürzen. Dies konnte erst durch die strikte Validierung mittels Pydantic und einer Retry-Logik behoben werden. Auch bei der Datenmodellierung traten massive Fehler auf: Anfänglich kombinierte String-IDs (z. B. 1_P001) verursachten Performance-Einbrüche, und fehlende Dubletten-Zuweisungen führten dazu, dass Einzelkunden fälschlicherweise in einem riesigen "Fehler-Cluster" zusammengefasst wurden. Diese Probleme wurden durch die Einführung einer globalen BIGINT-ID und DuckDB-funktionen (ROW_NUMBER()) gelöst. Auch musste der Staging- und Transformation mehrfach bearbeitet werden. Bspw. wurden die verschachtelten JSON und XML-Daten zu Beginn nicht richtig in die einzelnen Spalten aufgebrochen, weshalb die Daten unvollständig waren. Auch wurden

Datentypen teilweise falsch transformiert (z.B. Datum), weshalb sie in der verbund.db erstmal leer blieben. Diese Fehler wurden erst später erkannt und dementsprechend behoben.

Trotz der erfolgreichen Bereinigung ist der aktuelle Zustand der Datenbank noch nicht in allen Aspekten optimal. Ein ungelöstes Problem bleibt die referentielle Integrität bei den Behandlungsdaten. Da die Praxen Juckstadt und Schmidt teilweise Nachnamen statt eindeutiger IDs als Fremdschlüssel übergeben haben, musste die Zuordnung über einen komplexen LEFT JOIN (Kombination aus ID und Nachname) „erzwingen“. Dabei konnten so zwar alle Behandlungen gerettet werden, jedoch ist dieser Workaround auf Dauer nicht stabil. Spätestens in Szenario C könnte diese uneindeutige Referenzierung zu falschen Zuweisungen führen. Hier wäre dringend eine strukturelle Anpassung in den Quellsystemen der Praxen erforderlich.

4. Fazit:

Die Gegenüberstellung mit Team Brainicles zeigt deutlich den aktuellen Stand der Technik: Regelbasierte Algorithmen (Levenshtein) skalieren auf lokaler Hardware deutlich besser und liefern gute Gesamtmetriken. KI-gestützte Ansätze (Embeddings + LLM-Judge) sind aktuell noch deutlich ressourcenhungriger, bieten dafür aber ein überlegenes semantisches Kontextverständnis. Für dieses Szenario, in denen die „Regeln“, wann etwas als Dublette gilt, bereits fest vordefiniert ist, ist der regelbasierte Ansatz deutlich attraktiver, da sie schneller und ressourcenschonender arbeitet.

In der Realität sind diese Regeln nicht immer klar. Zum Beispiel kann eine Person auch mehrere Telefonnummern oder E-Mail-Adressen besitzen oder diese gewechselt haben. Ein Indikator dafür könnte das Erfassdatum sein. In solchen komplexeren Fällen, die auch den Kontext oder andere Faktoren beachten müssen, sind LLMs deutlich besser geeignet.

Für ein produktives System der Zukunft wäre eine Kombination ideal: Harte Blocking-Regeln für die Vorfilterung und ein LLM in der Cloud für die hochpräzise finale Fallentscheidung. Für diese simple Fallstudie hat sich jedoch der deterministische Weg als die bessere Variante erwiesen.